

心理学研究的 AI 进阶手册

从零散问答到可推进、可检查、可交接的个人研究项目

Hao Xie

2026-09-24

目录

推荐阅读方式	4
版本原则	4
开放许可与引用	4
使用说明	5
导读 为什么值得重新认识科研中的 AI	5
第 1 章 你做的其实是一个项目	5
1.1 “文件都在”为什么仍然会失控	6
1.2 为什么手工维护很容易失败	6
1.3 最低项目意识：先能回答六个问题	6
第 2 章 AI 已经从聊天框进入工作环境	7
2.1 模型、工具、运行框架与 Agent	7
2.2 我现在应该打开什么	7
2.3 五分钟能力自检	8
第 3 章 快速开始：第一次把 AI 放进一个真实研究项目	8
3.1 先选一个小任务，不必先建项目空间	9
3.2 一个够用的任务说明只需要五件事	9
3.3 六步完成第一个项目化任务	9
3.4 操作演示：让 AI 先做一次“项目体检”	10
第 4 章 文献、阅读与理论整理	10
4.1 “找到一篇文献”其实包含四个问题	10
4.2 适合交给 AI 的文献结构劳动	11

4.3 让文献卡直接服务后续写作	11
4.4 从发散到收束	12
4.5 操作演示：先审一条准备写进引言的主张	12
第 5 章 研究问题、设计与材料	12
5.1 从兴趣到可回答的问题	12
5.2 让 AI 帮你做设计批评	13
5.3 用 AI 生成和比较材料候选	13
5.4 把“计划做什么”和“实际做了什么”分开	13
5.5 操作演示：把“我想回答什么”拆成能回答与不能回答	13
第 6 章 数据、代码与统计分析	14
6.1 从原始数据到正文数字是一条链	15
6.2 非程序员需要看懂六件事	15
6.3 “运行成功”与“方法有效”至少隔着两层	15
6.4 要求 AI 汇报“研究影响”，而不只汇报代码 diff	16
6.5 AI 可以帮助数据清洗，但规则先由研究者确认	16
6.6 操作演示：先做只读审查，再决定是否修改	16
第 7 章 写作、修订与投稿	17
7.1 不同论文部分读取不同材料	17
7.2 写作的三个阶段	18
7.3 把审稿意见拆成项目任务	18
7.4 操作演示：把一段“写得很顺”的结果重新拆回证据	18
第 8 章 让 AI 帮你维护研究项目	19
8.1 最小项目结构只需五类材料	20
8.2 适合交给 AI 的项目维护劳动	20
8.3 课题组先统一最低接口	20
第 9 章 固定重复工作：任务说明、脚本与 Agent	21

9.1 一条自然升级路径.....	21
9.2 什么时候值得进一步封装或自动化.....	21
9.3 Agent 只在需要跨步骤行动时出现.....	22
9.4 什么时候不要自动化	22
9.5 多个 Agent 出现后，重点转向阶段治理	22
第 10 章 防止 AI 把研究带偏：核验、权限与恢复	24
10.1 按失败后果分配风险控制.....	24
10.2 分清五种质量活动	24
10.3 应由研究者保留的决定权.....	24
10.4 最小权限：先只读，再逐步增加	25
10.5 失败时先判断是否值得重试	25
10.6 数据、隐私与团队授权	25
结语 一个可以继续、可以检查、也可以交给别人的研究	26
附录 A 心理学研究常见 AI 场景速查	26
附录 B 最小个人项目模板.....	27
B.1 项目入口（README 或等价文件）	27
B.2 交接页（HANDOFF）	27
B.3 代码修改与研究影响记录	27
附录 C 当 LLM 本身进入研究设计	28
参考文献与动态来源说明.....	28
动态产品与政策来源（核查日期：2026-09-14）	30
AI 协作说明	32

这是一份面向心理学与社会科学学生、科研助理和导师的开放研究手册。它关注的不是“怎样让 AI 替你研究”，而是怎样把 AI 放进真实研究过程，减少版本比较、材料整理、项目维护、代码检查和结果一致性核对等结构性劳动，同时保留研究者对问题、方法、伦理与结论的最终判断。

阅读版与冻结版

当前网站是 **v1.2 的 HTML 阅读版**。对应的 PDF 与 DOCX 为同版正式发行文件；v1.1 的正文、PDF 与 DOCX 保留在历史版本中。

[下载 PDF 正式版](#) [下载 DOCX 正式版](#) [查看 GitHub Release](#)

推荐阅读方式

第一次阅读，建议先看“使用说明”和第 1—3 章；随后直接跳到当前任务对应的文献、研究设计、数据代码或写作章节。已经开始把 AI 放进真实项目的读者，可以继续阅读第 8—10 章。

如果你主要需要“今天具体打开哪个 AI 产品、API 是什么、怎样开始”，请配合动态更新的 [《心理学研究者的 AI Start Guide》](#) 使用。该配套指南与本手册分开维护：本手册保存相对稳定的方法原则，Start Guide 负责快速变化的产品与入口。

版本原则

- **v1.2 PDF / DOCX**：当前版本的正式发行文件。
- **HTML 阅读版**：与 v1.2 正文同步的在线阅读形态。
- **v1.1**：保留在 [历史 Release](#) 与 tag 中，不静默改写。
- **后续内容更新**：进入新的版本号，不静默改写已经冻结的发行文件。
- 产品能力、套餐、界面与政策会变化；相关动态事实均应以页面标注的核查时间和官方来源为准。

开放许可与引用

除另有说明外，本手册由作者拥有权利的原创内容采用 **Creative Commons Attribution 4.0 International (CC BY 4.0)** 许可。你可以复制、传播和改编本手册，包括用于商业用途，但需要进行适当署名、提供许可链接，并在有修改时说明修改。第三方引文、商标、截图或另有许可声明的材料不因此自动纳入本许可。

建议引用：

Xie, Hao. (2026). *心理学研究的 AI 进阶手册* (v1.2). <https://How-Tze.github.io/psych-ai-research-handbook/>

[查看版本记录 \(CHANGELOG\)](#)

使用说明

如果你已经用 AI 翻译、润色、解释统计或写过代码，但研究进度、文件版本和重要决定仍主要靠自己记住，这本手册就是从这里继续。它面向心理学与社会科学的学生、科研助理和导师，不要求编程基础，也不把复杂自动化当作目标。

全书的基本分工很简单：研究者负责科学判断，AI 承担适合结构化、比较、执行和检查的劳动。工作流也从这里开始：先让一次真实任务留下可继续、可检查的状态，复杂系统以后再说。

最短阅读路径：先读第 1—3 章，理解“研究为什么是项目、AI 在什么工作环境里、第一次怎么开始”；随后直接跳到与你当前任务最相关的第 4—7 章。第 8—10 章适合已经开始实际使用，希望进一步稳定项目和自动化方式的读者。

导读 为什么值得重新认识科研中的 AI

很多心理学研究者已经在使用 AI，常见用法包括翻译、润色、解释概念、生成代码，或者在卡住时问一个问题。近两年的变化在于，模型开始进入能够搜索、读文件、运行代码、操作目录和持续处理同一项目的工作环境。AI 因此可以参与一段研究过程，而不只生成一次回答。

这本手册把重点放在一类经常被忽略的工作上：整理材料、比较版本、维护状态、执行已确认的步骤，以及检查数据—结果—正文是否一致。AI 可以分担这些重复的结构性劳动，但研究决定仍由研究者负责。

贯穿案例 A：一个“文件都在”却难以继续的研究

一名研究生正在进行大学生压力、反刍与睡眠质量的横断问卷研究。问卷、数据、R 脚本、结果表和正文都还在，但各自有多个版本，正文数字无法立即追溯到当前分析。全书会沿着这个项目，看 AI 怎样从聊天工具逐步变成结构性助手。

第 1 章 你做的其实是一个项目

本章问题：为什么一项研究明明“文件都在”，仍然会越来越难继续、检查和交接？

心理学训练里，我们更常说“做毕业论文”“跑实验”“改文章”。但只要一项研究跨越多次工作，包含多个文件、决定和阶段，它就已经具备项目的基本特征。这里的“项目意识”不要求学习项目管理软件；先承认材料彼此依赖、变化会向下游传递，就够了。

1.1 “文件都在”为什么仍然会失控

案例 A：几个“最终版”

文件夹里同时有 data_clean.xlsx、data_clean_new.xlsx、analysis.R、analysis_new.R、结果表_final2.xlsx 和 manuscript_最终修改.docx。研究者大概记得哪份“应该”有效，却无法在五分钟内说明正文里的样本量由哪份数据、哪段代码和哪条排除规则产生。

研究对象

最常见的错位

问题与设计	研究问题或测量已经改变，方法说明仍沿用旧版本
材料与数据	原件被覆盖，或处理数据的版本含义不清
代码与规格	代码可以运行，但实现偏离原先决定
结果与正文	表图更新了，正文或摘要仍引用旧数字
决定与进度	组会决定、未决问题和下一步只存在于聊天或个人记忆

1.2 为什么手工维护很容易失败

传统做法默认研究者会一直记得自己做过什么：改完脚本顺手记一下，开完组会自己整理，换结果后再检查正文。问题是这些维护工作本身不产生直接的学术产出，却持续消耗注意力。项目越长、合作越多、版本越多，靠记忆和“final2”“new”之类文件名维持一致性的成本就越高。把原始材料、转换步骤和当前输出显式化，也与可复现计算的基本实践一致（Wilson et al., 2017; Sandve et al., 2013）。

AI 在这些维护工作上很有用：比较、整理、更新、追踪和检查。它可以降低维护成本，但不能替研究者决定哪一版在方法上有效。

1.3 最低项目意识：先能回答六个问题

1. 这个研究现在要回答什么问题？
2. 哪些材料是原始输入，默认不能覆盖？
3. 当前有效的问卷、数据、代码、结果和正文分别是哪一版？
4. 最近有哪些重要决定，为什么改变？
5. 当前做到哪里，还有哪些未决问题？
6. 如果当前版本有问题，应该回到哪个一致状态？

如果一个项目能稳定回答这六问，它已经具备基本的可继续性。后面介绍的来源追踪、检查点和交接页，都是在此基础上提高可靠性。

本章应用：不用整理全部文件。先写出“原始材料→处理数据→代码/分析规格→结果表图→正文”五个节点，并填上你认为当前有效的文件。凡是只能写“好像是……”的地方，都可以先让 AI 帮你梳理。

第 2 章 AI 已经从聊天框进入工作环境

本章问题：为什么同一个模型在不同产品里能做完全不同的事？

同一个模型，有时只能回答你粘贴进去的问题，有时却能搜索网络、读取整个文件夹、修改代码并运行测试。差异不只来自模型“聪不聪明”，还来自它被放在怎样的工作环境里。

2.1 模型、工具、运行框架与 Agent

概念	最简单的理解	研究中的例子
模型 (Model)	负责理解、生成和推理	解释统计输出、比较理论解释
工具 (Tool)	让模型访问外部能力	搜索、PDF/表格读取、Python/R、终端、文件操作
运行框架 (Harness)	决定模型看得到什么、能调用什么、有什么权限、怎样记录和何时停下	项目空间、代码代理工作区、带文件和工具的研究环境
Agent	在运行框架的边界内根据中间结果继续行动	检查文件 → 修改副本 → 运行测试 → 遇到边界请求确认

本手册把这一层称为“运行框架（Harness）”。可以把它理解成 AI 的工作台：台面上有什么材料、接了哪些工具、允许哪些动作、哪些步骤需要确认，都会改变 AI 实际能做的事。判断一个 AI 环境时，先问三件事：它能看见什么、能做什么、会留下什么记录。Harness 是当前 agent 工程中常用的概念之一，但不是跨厂商统一的产品分类。

2.2 我现在应该打开什么

你现在要做什么	更适合的工作环境	你实际会看到什么	先注意什么
讨论理论、解释概念、改一小段文字	普通对话	回答、改写、代码片段	正式依据仍回到真实材料
检索领域、追踪公开来源	联网搜索/深度研究类环境	带来源的候选文献或事实汇总	关键主张回原始来源核对
围绕同一研究持续读多份材料	项目型工作区（Project/Work space 等）	可复用明确加入项目的文件、知识或说明；跨对话上下文规则因平台而异	项目里“有文件”不等于它是当前有效版本
读取、修改	代码代理	目录、diff、终端输出、测试	先只读或改副

你现在要做什么	更适合的工作环境	你实际会看到什么	先注意什么
并运行代码	(Code Agent) / 本地代码环境	结果	本，再增加权限
跨文件、跨工具连续执行多步任务	Agent + 合适的运行框架	阶段性产物、工具调用、确认请求	先写清可见材料、权限和停止条件

这些名称只是工作环境的分类，不是产品认证。同一个产品可能同时提供普通聊天、项目空间和 Agent 模式。选择时先看任务需要哪些材料和工具，再看具体产品。

2.3 五分钟能力自检

- 上传一份无敏感信息的 PDF 或表格，要求它指出具体页、列或字段：如果可以，至少具备文件读取能力。
- 新开一次对话或任务后，看它能否继续访问你明确加入项目来源、知识库或固定说明的材料：如果可以，说明具备某种持续项目材料能力。不要假设所有平台都会自动共享旧聊天上下文。
- 要求它搜索公开资料并返回可核查来源：如果可以，可以用来找候选文献和方法资料。
- 让它列出代码目录并读取脚本，同时明确“不要修改”：如果可以，具备文件系统级代码审查能力。
- 允许它在副本中改一处代码、运行测试并给出 diff：如果可以，说明当前环境具备有限写入和执行能力。

不要把 Agent 当成成熟度指标。规则固定的转换通常交给脚本更稳妥；理论探索、方法争议和构念判断则适合保留在人机协作中。任务确实需要根据中间状态跨文件或工具行动时，再考虑 Agent。

本章应用：选你今天的一项任务，先问“AI 需要看见什么、调用什么”，再确认当前环境是否真的具备这些能力。够用即可，不追求功能最多。

第 3 章 快速开始：第一次把 AI 放进一个真实研究项目

本章问题：今天打开电脑后，我到底该怎么开始？

第一次使用不必先建复杂目录、学 Prompt 工程或安装 Agent。先选一个真实、有限、容易检查、做完能留下成果的任务。工作流可以从这样的任务逐步长出来。

3.1 先选一个小任务，不必先建项目空间

入口	第一次可以做什么	合适的起点
文献	把 5—10 篇已获得全文的论文整理成比较表	普通文件对话/项目型工作区；需要找资料时再用联网搜索或深度研究
数据/代码	让 AI 解释现有脚本读取什么、怎样处理样本和变量	先用能读取文件的环境做只读审查
写作	核对结果表与正文中的数字、模型名称和结论边界	把文字和对应证据一起交给 AI
项目整理	根据文件清单生成一页当前状态和冲突项	文件少时普通对话即可；文件多再用项目型工作区

不必先建立 Project/Workspace。只有两三个文件时，普通对话加本地文件夹就能开始。等材料增多、任务跨越多天，并且需要反复使用同一批项目来源时，再迁入持续项目空间。旧聊天是否会进入新任务上下文，取决于具体平台和项目设置。

3.2 一个够用的任务说明只需要五件事

1. 目标：这次要解决什么，不解决什么；
2. 输入：AI 可以读取哪些材料；
3. 输出：希望得到什么形式的产物；
4. 禁止项：哪些内容不得擅自补充、改变或解释；
5. 检查依据：你准备用什么材料或规则判断结果是否可用。

3.3 六步完成第一个项目化任务

1. 选一个今天本来就要做的真实任务。
2. 把这次任务依赖的材料放到明确位置，或明确 AI 可以读取哪些对象。
3. 用“五件事”交代任务。
4. 涉及代码、数据或多个文件时，先让 AI 复述它看见了什么、准备怎么做，再决定是否授权修改。
5. 先完成一个有限产物，例如文献比较表、项目状态草稿、代码只读审查或正文—结果一致性报告。

6. 由你核对确认，再把结果保存回项目；下一次从这个状态继续。

第一次只记住两件事

不要先设计复杂文件夹、研究复杂 Prompt、搭建复杂自动化，或把整篇论文和全部数据一次性交给 AI；要保存确认后的产物、主要输入位置、尚未解决的问题，以及涉及正式方法或结果时的研究者决定。

3.4 操作演示：让 AI 先做一次“项目体检”

案例 A 的第一步不需要代码代理。研究者只把文件清单、研究问题和自己已经确认的事实交给 AI，让它把混乱显式化。

目标：根据我提供的文件清单和说明，生成一页项目状态草稿。

输入：文件清单、当前研究问题，以及我明确确认过的事实。

输出：①可确认的文件及用途；②冲突或不确定处；③需要我决定的问题；④下一步建议。

禁止：不要凭“final”“new”“最终版”等文件名判断哪个版本有效；不要修改、删除或改名文件。

检查：每个“当前有效”的判断都要说明依据；依据不足就标记“待确认”。

如果 analysis.R 实际读取 data_clean.xlsx，而文件夹里还有 data_clean_new.xlsx，AI 应把它列成冲突，不应替研究者决定哪份才“最终”。正文写 N=312、当前结果表却是 N=298 时，也应先标成“不一致待核”，而不是自动改正文。

最后由研究者逐项确认。确认后的状态写回项目入口，无法确认的地方保留为未决问题。到这里，第一次项目化使用已经完成：AI 分担了整理工作，项目解释权仍由研究者掌握。

本章应用：现在就从“项目体检、文献主张核验、代码只读审查、正文—结果一致性检查”中任选一个，按六步完成一次任务。只有相同要求第二次、第三次出现时，再考虑把它固定成模板、脚本或更复杂的工作流。

第 4 章 文献、阅读与理论整理

本章问题：怎样让 AI 扩大文献处理能力，同时保证主张仍然能回到真实来源？

AI 能降低找资料、读资料 and 比较资料的成本，也容易把“候选线索”“真实来源”“原文结论”和“当前主张”写成一段看似连贯的话。文献工作因此要把这些状态分开处理。

4.1 “找到一篇文献”其实包含四个问题

1. 书目信息是否真实；

2. 全文或至少关键原文是否可访问；
3. 内容是否与当前问题相关；
4. 它是否真的支持你准备写出的这条主张。

这四个问题要分开处理。真实 DOI 不能保证 AI 对论文结论的概括准确；论文讨论中提到某种机制，也不代表研究设计直接检验了该机制。早期研究发现，生成式模型可能产生伪造或实质错误的书目信息，因此“找到来源”和“核对来源”应是两个步骤（Walters & Wilder, 2023；该研究评估的是当时的 GPT-3.5/GPT-4，不用于估计 2026 年模型的当前错误率）。

4.2 适合交给 AI 的文献结构劳动

- 根据研究问题拆分检索概念、同义词与相邻构念；
- 对已获得的论文提取统一字段；
- 生成可回到原文位置的文献卡；
- 把多篇研究按样本、设计、构念、测量和主要结果形成比较矩阵；
- 为已有理论解释提出竞争解释和反例问题；
- 对正文中的“主张—来源”配对做证据审计。

4.3 让文献卡直接服务后续写作

字段	最低内容
研究问题	作者真正试图回答什么
样本与设计	谁、什么设计、时间结构
构念与测量	关键变量如何操作化
主要结果	原文直接报告了什么
作者解释	作者如何解释结果
边界与限制	设计、样本与测量限制
与本项目关系	支持、部分支持、间接相关、暂不采用
定位信息	页码/章节/表图或可定位位置

案例 A：相关不等于机制

AI 在整理压力、反刍与睡眠文献时提出“压力通过反刍影响睡眠”的顺畅叙事。研究者要求它把每个来源拆为“原始发现”“作者解释”“当前项目候选推断”。结果显示部分来源只报告变量之间的关联，另一些在讨论中提出机制可能性。于是当前理论状态被写成“候选机制，需要更强设计检验”，而不是“已有研究证明”。

4.4 从发散到收束

AI 很容易生成更多构念、边界条件和机制，理论工作的难点却在收束。至少要回答：核心构念怎样界定；当前证据支持关联、条件规律还是机制；主要竞争解释是什么；什么观察会削弱当前解释；当前问题是否已经缩小到一个合理设计可以回答的范围。

4.5 操作演示：先审一条准备写进引言的主张

文献工作常见的问题，是从“读过几篇相关论文”直接跳到“一句话写进正文”。可以先挑一条关键主张，让 AI 只做证据对齐。

示例任务：

核验“较高压力会通过反刍损害睡眠质量”。只使用我提供的候选论文，不新增来源。逐篇返回：①书目是否可核；②原文直接报告了什么；③哪些只是作者解释；④支持层级（关联/候选机制/机制）；⑤当前最强可以写到什么程度。全文不可得、无法定位或证据不足时直接标记，不要补全。

一个合格的输出可能会指出：某篇研究只报告压力与睡眠的关联，另一篇只报告反刍与睡眠的关联，两者都没有识别“压力→反刍→睡眠”的时间顺序或因果机制。此时 AI 应把“通过”标为过强，而不是把两篇相关证据拼成一个机制结论。

研究者随后回到原文位置核对，再决定正文是否改成“反刍可能是值得进一步检验的候选解释”。AI 在这里节省的是定位、比较和结构整理时间；表述能写到多强，仍由研究者根据证据决定。

本章应用：建立一张主张—来源矩阵

从你当前引言中选 5 条关键主张。为每条主张记录来源、可访问状态、原文位置、支持强度和需要降级的措辞。这个任务非常适合 AI 协助整理，但“是否足以进入正文”的最终判断留给研究者。

第 5 章 研究问题、设计与材料

本章问题：怎样让 AI 帮你暴露设计问题、生成候选，而不替代构念与方法判断？

AI 可以帮助发现设计漏洞、比较操作化方案和生成材料候选。到了构念、样本、测量和因果识别这些环节，方法判断仍要由研究者完成。本章把 AI 放在“提出问题 and 整理结构”的位置。

5.1 从兴趣到可回答的问题

一个模糊兴趣常常混在一起谈描述、关联、预测和因果。可以让 AI 把它拆成不同主张层级，并说明每种主张需要什么设计证据。这样做能直接看出“我想写出的结论”和“当前设计能支持的结论”之间有多大距离。

5.2 让 AI 帮你做设计批评

- 构念边界是否含混；
- 测量是否与构念定义一致；
- 条件之间是否存在非预期差异；
- 样本和时间结构是否匹配研究问题；
- 模型中的变量是否在设计中有合理地位；
- 哪些结论会超过设计边界；
- 还需要哪些预测试、操纵检查或外部证据。

案例 A：先把“机制”从研究目标中降级

研究者最初口头上说“想看看反刍是不是压力影响睡眠的机制”。在设计审查中，AI 被要求区分横断问卷能支持什么。项目最终把当前目标改写为“描述压力、反刍与睡眠质量之间的关联，并评估反刍是否值得在后续纵向或实验研究中作为候选解释进一步检验”。这项决定由研究者确认并写入设计说明。

5.3 用 AI 生成和比较材料候选

问卷说明、实验情境、访谈提纲和操纵材料都可以先让 AI 生成多个候选版本。随后让它比较双重问题、措辞复杂度、条件长度差异和可能的诱导性表达。构念操作化、量表效度、操纵有效性和伦理则要回到相应证据。

5.4 把“计划做什么”和“实际做了什么”分开

预注册、研究计划、伦理申请和最终执行记录承担不同功能。研究过程中的偏离并不必然错误，但需要说明何时发生、为什么发生、是否在看过结果后发生，以及哪些下游材料受影响。AI 可以帮助比较计划稿与实际执行记录，但不能替研究者解释偏离是否合理。

5.5 操作演示：把“我想回答什么”拆成能回答与不能回答

设计阶段先别让 AI “给出最佳方案”。更实用的任务，是把一个容易说得过满的问题拆开，检查当前设计与预期结论是否对得上。

示例任务：

当前设计：一次横断问卷，同时测量压力、反刍和睡眠质量。

当前想法：想知道“反刍是不是压力影响睡眠的机制”。

请不要替我决定研究方案，只分成四部分：①当前设计可以回答什么；②不能回答什么；③至少三种竞争解释；④必须由研究者确认的方法问题。

对每一项说明原因，并把“统计上可以估计”与“设计上可以解释”分开。

在这个例子中，当前设计可以描述三个变量的关联模式，也可以估计某些统计关系；但它不能仅凭横断数据建立时间顺序或证明心理机制。横断中介分析尤其可能对纵向中介参数产生偏差，因此“统计上可以估计”不能自动升级为“机制已经得到识别”（Maxwell & Cole, 2007）。竞争解释还可能包括睡眠问题反过来增加反刍、一般负性情绪造成共同相关，以及测量内容重叠。

这类输出的作用，是把需要研究者决定的事项列清楚：研究目标是否降级、哪些分析属于探索、需要哪些协变量、是否应在后续研究加入纵向或实验设计。

本章应用：对当前设计做一次压力测试

把你当前研究问题交给 AI 做一次“设计压力测试”：要求它分别列出当前设计可以支持的主张、不能支持的主张、三种主要替代解释和需要研究者确认的方法问题。随后由你逐项采纳、拒绝或修改。

第 6 章 数据、代码与统计分析

本章问题：当 AI 已经能写和改代码时，研究者至少要看见哪些“研究含义”？

当代代码代理在获得相应权限后，可以读取代码目录、修改文件并运行命令或测试，获得代码帮助的操作门槛因此降低了。随之而来的问题是：代码能跑，并不代表研究者知道它改了什么。对非程序员来说，更重要的是看见这些改动对样本、变量、测量和模型意味着什么。

第一次使用 Code Agent 时，你应该看到什么：

1. 它先告诉你当前工作目录里有哪些相关文件，而不是直接开始改；
2. 它能说明准备读取和修改哪些文件，并把“方法问题”标成需要你决定；
3. 修改后能给出 diff、运行记录或测试结果，而不是只说“已经修好”；
4. 优先选择或配置能够限制只读、工作副本或关键动作确认的环境。

如果当前工具不提供清楚的权限控制，也可以让它只生成候选改动，再由研究者手工应用和运行；关键是不要把不可见的自动修改当成能力升级。

6.1 从原始数据到正文数字是一条链

阶段	研究者至少需要知道什么
原始数据	来源、导出日期、原件是否只读
清洗与计分	纳排、缺失、异常、反向计分、合成规则
分析数据	当前样本和变量版本
模型规格	因变量、自变量、交互、协变量、估计方法
代码实现	实际读取了什么、实现了哪份规格
输出与表图	由哪个模型/脚本产生
正文	哪些句子和数字引用了这些输出

6.2 非程序员需要看懂六件事

1. 输入是什么，哪些文件不得修改；
2. 样本如何进入、保留或排除；
3. 原始变量怎样变成分析变量；
4. 代码实现的是哪一份设计与模型规格；
5. 生成了哪些表、图和文字输入；
6. 改动失败或未经确认时回到哪里。

代码可以交给工具生成，但研究含义要保持可见。方法负责人检查构念、变量和模型，代码审查者检查实现，自动测试检查已经写明的不变量；三者覆盖的问题不同。科研代码审查也强调让实现、假设、测试和研究含义可以被外部检查（Rokem, 2024）。

6.3 “运行成功”与“方法有效”至少隔着两层

状态	它只说明什么
运行成功	代码执行并产生文件
测试通过	被写进测试的条件成立
符合规格	实现没有偏离已确认的样本、变量和模型规则
方法有效	这些规则本身适合研究问题、测量与设计

案例 A：能运行，也可能不该采用

24 行合成教学数据中，当前确认规则要求每个三题量表至少两题有效，一题按 `6-x` 反向计分，教学模型固定为 `sleep\_mean ~ stress\_mean + rum\_mean`。候选代码为了“让流程更干净”，改成九题全部完整、把反向计分写成 `5-x`，并加入年龄协变量。脚本运行成功，基础冒烟测试也通过，但规格测试发现样本数由 21 变为 15、哨兵分数错误、模型公式发生变化。研究者拒绝候选，保留确认后的基线。

6.4 要求 AI 汇报“研究影响”，而不只汇报代码 diff

- 样本是否改变；
- 变量构造是否改变；
- 测量项目或得分含义是否改变；
- 设计结构是否改变；
- 模型公式和分析地位是否改变；
- 结果、表图和正文是否需要重建；
- 输入、环境和复现顺序是否改变。

正文不要求新手记忆复杂模板。普通研究者首先需要的是份“代码修改与研究影响记录”：改了什么、为什么改、影响什么、怎样验证、如何重新生成、失败时回到哪里、谁决定是否采用。更完整的进阶模板放在配套控制资源中。

6.5 AI 可以帮助数据清洗，但规则先由研究者确认

AI 很适合扫描变量类型、缺失模式、重复记录、越界值和编码不一致，生成清洗报告与脚本。但“异常”不等于“应删除”，“缺失”也没有统一默认处理。凡是会改变样本、测量和模型的规则，都应先形成可见规格，再让代码执行。

6.6 操作演示：先做只读审查，再决定是否修改

遇到报错时，很容易直接让代码代理“帮我修好”。正式项目可以先从只读审查开始：让 AI 说明代码对研究做了什么，再决定是否允许修改。

示例任务：

目标：比较当前 analysis.R 与我提供的分析规格，先做只读审查。

允许读取：脚本、变量字典、分析规格和输出目录清单。

请报告：①读取和写入哪些文件；②样本筛选规则；③变量与反向计分规则；④模型公式；⑤生成哪些输出；⑥任何与规格不一致或无法确认的地方。

禁止：不要修改文件、删除数据、安装或升级依赖、改变样本规则或模型。
若信息不足，停在“未知”。

如果审查发现脚本要求九题全部完整，而规格写的是“每个三题量表至少两题有效”；或者反向计分写成 5-x、模型又额外加入年龄，第一步应先列出偏差清单，再决定是否修代码。

只有研究者确认哪些属于实现错误、哪些需要另立方法决定后，才进入第二步：在副本或有限写入范围内生成候选补丁，再运行测试并比较样本、变量、模型和下游输出。这个顺序体现了运行框架的作用：同一个模型先处在只读环境，再按任务证据逐步增加权限。

本章应用：做一次代码影响审计

让 AI 对一个当前分析脚本做“代码影响审计”，只回答样本、变量、测量、模型、输出和复现六个问题，先不修改代码。如果你仅根据这份报告就能说明脚本对研究做了什么，代码代理才具备进入正式项目所需的基本可见性。

第 7 章 写作、修订与投稿

本章问题：怎样让 AI 提高写作与修改效率，却不让语言跑到证据前面？

写作往往最先让人感到 AI 的效率，但语言也很容易走在证据前面。稳妥的做法是让不同章节读取相应的当前有效材料，并把生成、作者判断和独立核验分开。

7.1 不同论文部分读取不同材料

论文部分	应优先读取	不应凭空补全
引言	已核文献、理论矩阵、研究问题	不存在的文献或未经核实的机制结论
方法	实际执行记录、材料版本、分析规格	计划中写过但最终没做的程序
结果	当前确认的模型、结构化输出、样本流	讨论性解释或记忆中的旧数字
讨论	本研究结果、已核文献、作者解释	把作者解释包装成结果

论文部分	应优先读取	不应凭空补全
摘要/标题	最终全文和最终模型	旧草稿数字或更强的因果措辞

7.2 写作的三个阶段

1. 生成：根据指定输入形成局部候选并标记缺口；
2. 作者判断：决定主次、解释、贡献和取舍；
3. 独立核验：不再润色，只检查来源、数字、边界和跨文件一致性。

让同一个模型先写再“自查”可以发现一部分问题，但不能替代独立证据。数字核对回到实际输出，文献支持回到原文，方法判断回到设计和规格。

案例 A：一句话怎样返回上游

AI 在结果草稿中写出“压力通过反刍导致睡眠质量下降”。项目检查发现三处越界：横断数据不能支持“导致”；当前分析没有建立机制识别；文献矩阵也只把反刍标为候选解释。这时应回到结果与理论状态，把表述降到当前证据能支持的关联层级。

7.3 把审稿意见拆成项目任务

审稿意见可以拆成问题、决定、行动和证据。凡是会改变样本、变量、模型或结论的行动，都回到相应上游重新确认。回复信里写“已完成”时，应能指向真实修改和对应证据。

字段 示例问题

审稿问题	审稿人真正担心什么
作者决定	接受、部分接受、澄清、无法执行或有理据不同意
实际行动	修改哪份文件/分析
上游影响	是否改变数据、变量、模型或结论
回复证据	新表、新分析、原文位置或修改段落

7.4 操作演示：把一段“写得很顺”的结果重新拆回证据

写作阶段可以暂时关掉“润色”任务，只问 AI：“这句话凭什么能写？”这样更容易把语言流畅度和证据强度分开。

示例任务：

材料：这一段结果/讨论文字、当前系数表、样本流、设计说明和已经核实的文献矩阵。

请逐句标记：①本研究数值性主张；②外部文献性主张；③作者解释；④无法支持或超过设计边界的主张。

为每句话指出对应依据和处理建议。先不要改写文字；找不到依据时写“待核/删除/返回上游”。

例如，“压力与较差睡眠质量相关”如果能返回当前模型和对应系数，可以保留；“反刍中介了压力对睡眠的影响”若当前设计和分析不足以支持机制，应直接返回设计或分析链；“这一模式提示反刍值得在后续研究中进一步检验”则属于作者解释，应明确以解释性语气出现。

审稿回复也可以沿用同一结构：先把意见拆成“问题—决定—行动—证据”，再生成回复文字。先保证修改与证据对应，最后再处理礼貌和语言。

投稿政策属于动态事实。以 APA Journals 截至 2026-09-14 的通用政策为例，生成式 AI 若用于稿件起草，需要在稿件中披露并引用，AI 不能列为作者，作者仍对信息与引文的准确性负责。具体期刊可能增加更严格的披露位置、补充材料或保密要求，因此正式投稿前应重新核查目标期刊当时有效的作者指南。若你以审稿人或编辑身份处理未公开投稿，APA 当前政策还明确禁止把提交内容输入生成式 AI 工具，以保护同行评审保密性（American Psychological Association, n.d.; 核查于 2026-09-14）。

本章应用：做一次证据对齐检查

选一页当前结果或讨论，让 AI 做“证据对齐检查”，而不是润色：每个数字来自哪个输出？每个文献性主张来自哪个来源？哪些句子属于作者解释？哪些句子超过当前设计边界？

第 8 章 让 AI 帮你维护研究项目

本章问题：怎样把已经产生的文献、代码、结果和决定维持成一个仍然可理解的项目？

到这一章，你已经看过 AI 怎样进入文献、设计、分析和写作。接下来只做一件事：把已经产生的材料、决定和检查结果集中到少数固定位置，让“当前什么有效”不再依赖记忆。

平台里的项目型工作区可以让你在多次任务中复用明确加入的文件、知识库或项目说明；有些平台还提供项目级记忆。聊天之间怎样共享上下文、记忆和历史并不统一，不能假设旧对话会自动进入新任务。正式数据、代码和研究结论仍应有你自己能够定位的保存位置。

8.1 最小项目结构只需五类材料

材料	它回答什么
项目入口	这是什么研究，从哪里开始看
受保护原件	哪些数据、材料和外部原文默认不覆盖
工作材料与当前成果	哪些正在修改，哪些已经可以进入下一步
决定与变化记录	重要方法或状态为什么改变
当前状态 / 交接页	现在什么有效、卡在哪里、下一步是什么

这五类内容不一定对应五个文件。小项目可以把它们合并在一两页说明中；项目变复杂以后，再拆分版本记录、来源记录或团队规则。先保证别人能够找到入口、原件、当前成果、重要决定和下一步。

8.2 适合交给 AI 的项目维护劳动

- 扫描项目文件并生成文件地图；
- 比较版本，提取新增、删除和实质变化；
- 把研究者确认过的组会或聊天决定整理进决定记录；
- 根据研究者确认的输出更新当前状态；
- 在数据、模型或材料改变后，列出可能需要重做的表图与正文位置；
- 生成交接页草稿，并标出无法从现有材料确认的事项。

AI 只根据已经确认的事实整理关系，不替研究者宣布哪份文件“最终有效”。它可以降低维护成本，最终解释权仍由研究者掌握。

案例 A：项目第一次真正可交接

项目入口现在能定位原始问卷导出、当前变量字典、分析规格、当前脚本、研究者确认的输出和正文。交接页只写当前状态与未决问题。新成员不需要重读几十轮旧聊天，就能知道下一步是“核对两条文献主张并重跑当前稳健性规格”，而不是重新猜测全部历史。

8.3 课题组先统一最低接口

如果课题组里的项目在理论、设计和分析上差异很大，不必先统一整套研究流水线。可以先统一几个最低接口：原始数据不可覆盖；每个项目有一个入口；明确当前有效版本；重要方法变化留下理由；正文数字能够返回输出；交接时提供当前状态和未决事项。具体工具、目录和自动化程度由各项目决定。

本章应用：写一页交接页（HANDOFF）

假设你明天要把项目交给另一个同学。只用一页回答：项目目标、当前有效输入、当前成果、最近关键决定、未决问题、下一步，以及出现问题时从哪里恢复。让 AI 根据项目材料先起草，你逐项确认；无法确认的地方直接标记未知。

第 9 章 固定重复工作：任务说明、脚本与 Agent

本章问题：什么时候应该继续人工协作，什么时候才值得把重复任务固定或自动化？

工作流通常先从真实任务开始。第一次用清楚的任务说明完成；第二、第三次发现输入、输出和检查方式都很相似，再把不变部分保存下来。

9.1 一条自然升级路径

一次人工完成 → 保存有效任务说明 (Prompt) → 多次使用后形成模板或 SOP → 确定性规则交给脚本 → 边界稳定的 AI 方法可以封装为 Skill → 只有确实需要根据中间状态跨步骤行动时才使用 Agent。

形式	适合解决什么	不适合承担什么
任务说明 (Prompt)	当前一次任务的目标、输入、输出和限制	整个项目的长期状态
模板 / SOP	重复任务中人与工具的协作顺序、交接和确认点	代替实际执行和研究证据
脚本	规则已经明确、每次都应一致执行的转换	规则未定时自行选择研究方法
Skill	输入输出和检查方式较稳定的可复用 AI 方法	因为被封装就自动变得正确
Agent	需要根据中间状态在文件或工具之间选择下一步	自行扩大权限或改变研究问题

9.2 什么时候值得进一步封装或自动化

1. 任务已经真实重复出现；
2. 方法和边界相对稳定；
3. 输入和输出能够清楚描述；
4. 常见失败和“不知道”能够表示；
5. 可以设置检查方式和人工确认点；
6. 复用确实减少不一致，而不是掩盖项目差异。

规则完全确定时，优先用脚本。若仍需要模型按一套稳定方法处理不同材料，可以考虑 Skill；任务需要根据中间结果选择下一步、跨文件或工具行动时，再

考虑 Agent。“Skill”目前被多家 AI 平台用于指代可复用 workflow 或能力包，但具体格式、安装方式和可用范围并不相同；本书把它作为便于讨论的统称。封装能减少重复劳动，但不会自动增加方法效度。

9.3 Agent 只在需要跨步骤行动时出现

Agent 的区别不在于 Prompt 更长，而在于它会根据中间结果继续行动。只有当可见材料、权限、停止点和人工确认都能写清时，这种执行方式才值得采用。具体能力仍取决于第 2 章介绍的运行框架（Harness），权限按任务需要逐步增加。

案例 A：把“结果—正文一致性检查”固定下来

两轮修改都需要核对样本量、模型名称、系数、表图编号和因果措辞。研究者先保存一份检查任务说明，再形成固定表格模板。只有当项目能稳定提供结构化结果表和正文位置后，才考虑封装为可复用 Skill；它仍只标记问题，不自动改写正式结论。

9.4 什么时候不要自动化

- 方法规则仍在争议；
- 无法定义什么算关键错误；
- 输入高度不稳定，每次都需要重新解释；
- 一次失败可能无痕覆盖正式状态；
- 人工复核能力跟不上自动处理规模；
- 维护权限、版本和依赖的成本大于节省的劳动。

9.5 多个 Agent 出现后，重点转向阶段治理

即使任务已经适合使用 Agent，再增加 Agent 也不会自动让 workflow 更成熟。多 Agent 更适合那些能够拆开、结果可以检查，而且并行推进确实能减少等待时间的任务。如果任务彼此高度依赖、规则仍在变化，或者每一步都需要重新判断研究方向，多开几个 Agent 反而会增加协调和复核成本。

这时，一个重要变化是要区分**执行性问题**与**战略性问题**。执行性问题可以在已经确认的目标和规则内解决，例如文件是否完整、链接是否有效、代码是否通过测试、产出是否符合既定规格。战略性问题则会改变项目本身，例如需要调整研究问题、分析规格、证据标准、任务范围或验收条件。前一类问题可以让 Agent 在明确边界内自行处理；遇到后一类问题时，应暂停执行，重新交给研究者判断。

这样的区分也改变了对话模型在 workflow 中的位置。如果每个 Agent 做完一步，都必须回到同一个对话讨论‘下一步做什么’，表面上虽然用了多个 Agent，实际

流程仍然是串行的。更有效的方式，是在一个阶段开始前先确定目标、任务边界、验收标准和需要升级的问题，再让 Agent 在这些条件内推进。只有当既有条件不足以继续决策时，才重新进入更深的分析。

因此，协作所依赖的状态也不能只存在于聊天记录中。第 8 章介绍的项目入口、当前有效状态、决定记录和交接页，可以进一步成为不同 Agent 接力工作的共同参照。这里并不意味着把所有研究材料都放入 Git 或任何单一平台：敏感数据和受限材料仍应保存在合适的位置，项目文件保存的是可以安全共享的规格、已经确认的决定、当前状态以及指向受控材料的必要信息。

对于影响较大、需要反复执行或可能交接给其他 Agent 的工作，还可以把一次性的任务说明进一步固定成**任务规格**。例如，一项“结果—正文一致性检查”可以写成：

目标：核对当前确认结果表与正文中的样本量、模型名称、系数和表图编号。

输入：当前确认结果表、待检查正文。

输出：问题列表及对应位置，不直接改写正文。

验收：正文中的所有报告数字都能追溯到当前结果表中的对应项。

禁止：改变分析、补造结果或自动修改正式结论。

升级：若正文与结果来自不同分析版本，停止执行，由研究者确认当前有效版本。

有了这样的边界，不同 Agent 才适合在彼此依赖较少的任务上并行：一个检查链接和引用，一个核对代码与输出，一个整理交接材料。并行主要减少的是等待时间，并不会自动减少计算量，也会带来额外的协调成本。

第二个 Agent 也不能被当作第二份独立证据。它可以帮助发现遗漏、测试实现或从另一个角度检查结果，但如果多个 Agent 依赖相同材料、假设或相近模型，它们仍可能产生相关错误。第 10 章的原则仍然适用：验证、独立审计、人工复核和复现承担不同功能，“两个模型意见一致”本身不能替代来源、方法和研究者的判断。多 Agent workflow 真正改变的，是研究者不再需要逐步告诉每个工具下一步做什么，而是更多地负责定义阶段、设置边界、处理升级问题，并对最终结果作出验收。

本章应用：判断一个重复任务应该停在哪一层

从你最近一个月重复至少两次的任务中选一个。先写清不变输入、不变步骤、输出、失败状态和人工检查点，再决定它应该停在哪一层。若这个任务确实需要多个 Agent 协同，再补写阶段目标、各任务边界、验收标准和升级条件。能用简单形式可靠完成，就不要为了“高级”继续升级。

第 10 章 防止 AI 把研究带偏：核验、权限与恢复

本章问题：怎样根据失败后果配置核验、权限和恢复？

到这里再系统讨论风险，读者已经见过具体任务，也更容易理解每项控制在防什么。可靠性的目标，是让重要错误有机会被发现、阻断、追踪并恢复。

10.1 按失败后果分配风险控制

大致风险	典型任务	最低做法
较低	不含结果的措辞润色、格式整理、想法发散	快速人工比较，保留原意
中等	文献概括、代码修改、结果段候选、批量提取	按来源、字段或规则核验，配合抽查并保留输入输出
较高	样本排除、变量定义、模型变化、伦理、因果结论、正式提交	明确规格、独立证据/方法判断、人工确认与回退

这里的三级风险只是本手册用于快速分流任务的简化框架，并非 NIST 或其他机构发布的统一风险等级。它借鉴一般风险管理思路：根据使用情境、后果、可发现性、可恢复性和现有控制来调整治理强度（NIST, 2023；Autio et al., 2024）。判断时重点看五件事：任务是否进入正式证据、是否改变方法或伦理、错误是否难发现、能否完整恢复、后果是否会扩散到其他文件和决策。

10.2 分清五种质量活动

活动	回答的问题
生成	能产生什么候选
验证	是否满足已知规格、数字、来源或字段要求
独立审计	还有什么遗漏、过强推断或系统性错误
人工复核	是否采纳、修改、拒绝或升级
复现	从规定输入、版本和环境能否重新得到预期产物

结构合法不等于内容正确；代码运行不等于符合研究规格；两个模型意见一致不等于获得独立证据；能够重跑也不等于研究设计有效。

10.3 应由研究者保留的决定权

- 研究问题与理论贡献；
- 构念界定与关键测量选择；
- 样本纳排和重要数据处理规则；

- 模型与分析地位；
- 因果和机制解释；
- 研究伦理与敏感数据处理；
- 正式结论与提交。

10.4 最小权限：先只读，再逐步增加

1. 只读审查：列文件、风险和所需信息；
2. 计划与候选补丁：说明拟改内容和影响，由人决定是否应用；
3. 有限写入：只修改指定副本或目录；
4. 确认后执行：运行已确认的脚本和测试，并在关键节点暂停；
5. 有界自动执行：仅用于规则稳定、错误可发现、结果可回退的重复任务。

10.5 失败时先判断是否值得重试

服务暂时不可用、文件锁定或格式解析失败，可以有限重试。若问题来自输入含义不明、规格矛盾或新的方法分支，重复运行不会带来更多信息，此时应停止。记录失败发生在哪个对象、已经改变了什么、哪些输出不得使用，以及恢复后从哪一步重新开始。恢复时要把输入、规格、代码、输出和正文恢复到彼此一致的状态，不能只换回某一个旧文件。

案例 A：三类故障如何被发现

文献链中，证据矩阵阻止“相关”升级为“机制”；代码链中，规格测试阻止未经确认的样本、计分和模型变化；写作链中，正文—输出核对阻止旧结果继续留在摘要。可靠工作流的作用，是尽量阻止错误无声穿过整个项目。

10.6 数据、隐私与团队授权

个人账户能够访问某项工具，不表示团队或机构已经授权它处理共同数据。未公开论文、被试数据、访谈资料、API 密钥和受版权限制全文需要按机构政策和工具当前政策处理。为了追踪方便而把敏感原文复制进普通日志，同样可能扩大风险。

本章应用：用三问完成一次风险分诊

任务很小且明显可逆时，先问三句：它会进入正式证据吗？会改变方法或伦理吗？出错后能完整恢复吗？任一答案为“是”或“不确定”，就升级到更完整的任务规格、验证、人工节点和回退设计。

结语 一个可以继续、可以检查、也可以交给别人的研究

判断 AI 是否改善了科研流程，不看用了多少模型、安装了多少 Skill，也不看 Agent 数量。更实际的标准是：研究是否更容易推进、检查和恢复。

假设你明天把项目交给另一个同学。对方能否在不重读全部聊天的情况下回答：研究问题是什么？原始材料在哪里？哪个版本有效？重要决定为什么发生？结果来自哪份数据和哪段代码？正文哪些地方引用或使用了这些结果？当前卡在哪里？下一步从哪里开始？

如果这些问题都能回答，AI 的价值就已经超出几段文字生成：它开始降低项目维护、检查和交接的成本。

把本手册的 AI 工作流压缩成一句话：研究者保留科学判断，项目保存可恢复状态，AI 承担适合自动化或结构化的劳动。

附录 A 心理学研究常见 AI 场景速查

场景	AI 主要帮助	研究者保留的判断	建议保存的产物
理论探索	候选机制、竞争解释、概念比较	构念边界与理论贡献	问题树/理论矩阵
文献导读	提取、比较、定位	证据支持判断	文献卡/主张—来源矩阵
问卷/材料	生成候选、比较版本、语言检查	操作化与效度判断	材料版本与修改理由
数据清洗	扫描异常、生成脚本、报告变化	规则与排除决定	清洗规格/报告/脚本
统计分析	实现规格、运行、测试、表图	模型合理性与分析地位	分析规格/输出/影响记录
论文写作	结构、局部起草、一致性检查	解释、贡献、正式结论	候选稿/核验表
审稿修改	拆意见、追踪任务、比较版本	接受/拒绝与方法决定	修改矩阵/交接页
项目交接	文件地图、状态整理、未决项	当前有效状态确认	项目入口/交接页

附录 B 最小个人项目模板

B.1 项目入口（README 或等价文件）

- 项目一句话目标；
- 当前阶段；
- 原始材料位置；
- 当前有效问卷/数据/代码/输出/正文位置；
- 最近关键决定；
- 当前未决问题；
- 从哪里恢复。

B.2 交接页（HANDOFF）

- 当前目标；
- 有效输入和产物；
- 已经确认的决定；
- 哪些材料不得修改或外传；
- 当前阻塞与未决问题；
- 下一步；
- 最近一致检查点。

B.3 代码修改与研究影响记录

- 改了什么；
- 为什么改；
- 影响样本/变量/测量/设计/模型/结果中的哪些项；
- 运行了什么测试和人工检查；
- 如何重新生成；
- 如何回退；
- 研究者决定：候选、拒绝或确认。

附录 C 当 LLM 本身进入研究设计

前十章默认 AI 主要作为研究辅助工具。若模型输出本身成为编码、评分、材料、合成响应或直接研究对象，证据要求随之提高，本附录把这些情形单独作为进阶专题。行为科学中的 LLM 研究报告可参考 Feuerriegel et al. (2026); TRIPOD-LLM (Gallifant et al., 2025) 主要面向医疗与健康场景，不宜当作所有心理学 LLM 研究的统一报告标准。

角色	输出功能	首要验证对象
研究辅助工具	整理候选或执行受限步骤	是否忠实完成已确认任务
编码器/分类器	给人类材料生成标签或分数	与编码规则和独立参照的关系
评价器 (judge)	比较或评分其他产物	量尺、偏差与外部校准
材料生成器	生成刺激、项目或情境	操作化、预测试与非预期差异
合成响应/模拟器	生成流程测试数据或条件化响应	既定用途与真实参照
直接研究对象	模型行为本身成为观测	配置、输入、重复、失败和版本

关于模型行为的观察不能自动升级为关于人类群体或心理机制的结论。最低实验单元应包含可识别系统与运行环境、版本化输入、一次运行及其状态、原始输出、失败与人工处理 (Feuerriegel et al., 2026) 。在方法记录中，synthetic persona 更适合作为模型的生成条件或角色设定来描述，不应与人类参与者等同；把 LLM 合成响应当成人类调查数据替代物也存在方差、回归结构、提示敏感性与时漂移等已知问题 (Dillion et al., 2023; Bisbee et al., 2024) 。LLM-as-a-judge 是评价器，其输出需要外部校准，并可能受到位置、冗长和自我偏好等偏差影响，不应被当成真值 (Zheng et al., 2023) 。

参考文献与动态来源说明

事实与时效核查日期：2026-09-14。以下学术与标准来源支持本手册关于可复现研究、项目状态、代码审查、人机协作、AI 风险和 LLM 研究边界的主要论述。产品能力、项目记忆、权限、订阅和期刊 AI 政策变化较快，因此另列当前官方动态来源。正文尽量按“能做什么”组织，避免绑定具体按钮名称。

National Academies of Sciences, Engineering, and Medicine. (2019). Reproducibility and Replicability in Science. National Academies Press. <https://doi.org/10.17226/25303>

W3C Provenance Working Group. (2013). PROV-O: The PROV Ontology. W3C Recommendation. <https://www.w3.org/TR/prov-o/>

Wilkinson, M. D., Dumontier, M., Aalbersberg, I. J., et al. (2016). The FAIR Guiding Principles for scientific data management and stewardship. *Scientific Data*, 3, 160018. <https://doi.org/10.1038/sdata.2016.18>

Wilson, G., Bryan, J., Cranston, K., Kitzes, J., Nederbragt, L., & Teal, T. K. (2017). Good enough practices in scientific computing. *PLOS Computational Biology*, 13(6), e1005510. <https://doi.org/10.1371/journal.pcbi.1005510>

Sandve, G. K., Nekrutenko, A., Taylor, J., & Hovig, E. (2013). Ten Simple Rules for Reproducible Computational Research. *PLOS Computational Biology*, 9(10), e1003285. <https://doi.org/10.1371/journal.pcbi.1003285>

Parasuraman, R., & Manzey, D. H. (2010). Complacency and bias in human use of automation: An attentional integration. *Human Factors*, 52(3), 381–410. <https://doi.org/10.1177/0018720810376055>

National Institute of Standards and Technology. (2023). Artificial Intelligence Risk Management Framework (AI RMF 1.0). NIST AI 100-1. <https://doi.org/10.6028/NIST.AI.100-1> (截至 2026-09-14, 1.0 仍为公开现行框架, NIST 正在修订。)

Autio, C., Schwartz, R., Dunietz, J., Jain, S., Stanley, M., Tabassi, E., Hall, P., & Roberts, K. (2024). Artificial Intelligence Risk Management Framework: Generative Artificial Intelligence Profile. NIST AI 600-1. <https://doi.org/10.6028/NIST.AI.600-1>

National Institute of Standards and Technology. (2020). NIST Privacy Framework: A Tool for Improving Privacy Through Enterprise Risk Management, Version 1.0. NIST CSWP 10. <https://doi.org/10.6028/NIST.CSWP.10> (截至 2026-09-14, 1.1 仍为 Initial Public Draft / “Coming soon”。)

Souppaya, M., Scarfone, K., & Dodson, D. (2022). Secure Software Development Framework (SSDF) Version 1.1: Recommendations for Mitigating the Risk of Software Vulnerabilities. NIST SP 800-218. <https://doi.org/10.6028/NIST.SP.800-218> (截至 2026-09-14, Version 1.2 仍为 Initial Public Draft。)

Rokem, A. (2024). Ten simple rules for scientific code review. *PLOS Computational Biology*, 20(9), e1012375. <https://doi.org/10.1371/journal.pcbi.1012375>

Walters, W. H., & Wilder, E. I. (2023). Fabrication and errors in the bibliographic citations generated by ChatGPT. *Scientific Reports*, 13, 14045. <https://doi.org/10.1038/s41598-023-41032-5> (该研究评估的是当时的 GPT-3.5 / GPT-4; 用于说明“引用必须核验”, 不用于估计 2026 年模型的当前错误率。)

Eronen, M. I., & Bringmann, L. F. (2021). The Theory Crisis in Psychology: How to Move Forward. *Perspectives on Psychological Science*, 16(4), 779–788. <https://doi.org/10.1177/1745691620970586>

Appelbaum, M., Cooper, H., Kline, R. B., Mayo-Wilson, E., Nezu, A. M., & Rao, S. M. (2018). Journal article reporting standards for quantitative research in

psychology: The APA Publications and Communications Board task force report. *American Psychologist*, 73(1), 3–25. <https://doi.org/10.1037/amp0000191>

Steege, S., Tuerlinckx, F., Gelman, A., & Vanpaemel, W. (2016). Increasing Transparency Through a Multiverse Analysis. *Perspectives on Psychological Science*, 11(5), 702–712. <https://doi.org/10.1177/1745691616658637>

Hernán, M. A. (2018). The C-Word: Scientific Euphemisms Do Not Improve Causal Inference From Observational Data. *American Journal of Public Health*, 108(5), 616–619. <https://doi.org/10.2105/AJPH.2018.304337>

Maxwell, S. E., & Cole, D. A. (2007). Bias in cross-sectional analyses of longitudinal mediation. *Psychological Methods*, 12(1), 23–44. <https://doi.org/10.1037/1082-989X.12.1.23>

Feuerriegel, S., Barrie, C., Crockett, M. J., et al. (2026). A reporting checklist for large language models in behavioural science. *Nature Human Behaviour*, 10, 1182–1186. <https://doi.org/10.1038/s41562-026-02492-7>

Gallifant, J., Afshar, M., Ameen, S., et al. (2025). The TRIPOD-LLM reporting guideline for studies using large language models. *Nature Medicine*, 31, 60–69. <https://doi.org/10.1038/s41591-024-03425-5>

Mitchell, M., Wu, S., Zaldivar, A., et al. (2019). Model Cards for Model Reporting. *Proceedings of the Conference on Fairness, Accountability, and Transparency (FAT* '19)*, 220–229. <https://doi.org/10.1145/3287560.3287596>

Dillion, D., Tandon, N., Gu, Y., & Gray, K. (2023). Can AI language models replace human participants? *Trends in Cognitive Sciences*, 27(7), 597–600. <https://doi.org/10.1016/j.tics.2023.04.008>

Bisbee, J., Clinton, J. D., Dorff, C., Kenkel, B., & Larson, J. M. (2024). Synthetic Replacements for Human Survey Data? The Perils of Large Language Models. *Political Analysis*, 32(4), 401–416. <https://doi.org/10.1017/pan.2024.5>

Zheng, L., Chiang, W.-L., Sheng, Y., et al. (2023). Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. *Advances in Neural Information Processing Systems*, 36, 46595–46623. <https://doi.org/10.52202/075280-2020>

Amershi, S., Weld, D., Vorvoreanu, M., et al. (2019). Guidelines for Human-AI Interaction. *Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems*, Paper 3, 1–13. <https://doi.org/10.1145/3290605.3300233>

动态产品与政策来源（核查日期：2026-09-14）

以下条目用于核查正文中容易变化的产品能力、运行框架、项目空间、Skill、标准版本与投稿政策。它们不是产品推荐，也不代表功能会长期保持不变。正式发布或实际使用前，凡涉及按钮入口、跨聊天记忆、权限模式、可用数据源、订阅范围、期刊政策与标准版本，都应重新核查官方来源。

OpenAI. (n.d.). Projects in ChatGPT. OpenAI Help Center. 核查于 2026-09-14.
<https://help.openai.com/en/articles/10169521-projects-in-chatgpt>

OpenAI. (n.d.). Deep research in ChatGPT. OpenAI Help Center. 核查于 2026-09-14. <https://help.openai.com/en/articles/10500283-deep-research-faq>

OpenAI. (2026, September 10). Introducing the Agents API.
<https://openai.com/index/introducing-the-agents-api/>

OpenAI. (2026, April 10). Using skills. OpenAI Academy.
<https://openai.com/academy/skills/>

Anthropic. (n.d.). How can I create and manage projects? Claude Help Center. 核查于 2026-09-14. <https://support.claude.com/en/articles/9519177-how-can-i-create-and-manage-projects>

Anthropic. (2026, March 24). Harness design for long-running application development. <https://www.anthropic.com/engineering/harness-design-long-running-apps>

Google. (n.d.). Use Deep Research in Gemini Apps. Gemini Apps Help. 核查于 2026-09-14. <https://support.google.com/gemini/answer/15719111>

American Psychological Association. (n.d.). APA Publishing Policies: Policy on the use of generative artificial intelligence (AI) in scholarly materials. 核查于 2026-09-14. <https://www.apa.org/pubs/journals/resources/publishing-policies>

Anthropic. (2025, October 16). Equipping agents for the real world with Agent Skills. Anthropic Engineering. 核查于 2026-09-14.
<https://www.anthropic.com/engineering/equipping-agents-for-the-real-world-with-agent-skills>

Anthropic. (2026, March 25). How we built Claude Code auto mode: a safer way to skip permissions. <https://www.anthropic.com/engineering/claude-code-auto-mode>

OpenAI. (2026, February 2; updated March 4). Introducing the Codex app.
<https://openai.com/index/introducing-the-codex-app/>

Google. (2026, June 22). Measuring What Matters with Jules. Google Developers Blog. <https://developers.googleblog.com/measuring-what-matters-with-jules/>

National Institute of Standards and Technology. (n.d.). AI Risk Management Framework. 核查于 2026-09-14. <https://www.nist.gov/itl/ai-risk-management-framework>

National Institute of Standards and Technology. (n.d.). Privacy Framework 1.1. 核查于 2026-09-14. <https://www.nist.gov/privacy-framework/new-projects/privacy-framework-version-11>

National Institute of Standards and Technology. (2025, December 17). SP 800-218 Rev. 1 (Initial Public Draft): Secure Software Development Framework (SSDF) Version 1.2. 核查于 2026-09-14. <https://csrc.nist.gov/pubs/sp/800/218/r1/ipd>

AI 协作说明

v1.1 在结构重写、贯穿案例设计、文本起草和文件生成过程中使用了 AI 辅助。作者负责确定手册定位、读者、方法立场与案例边界，并对进入正式发布版本的主张、来源、许可、隐私、研究诚信和最终内容负责。教学案例中的数据与故障不构成心理学研究结果。